

lab01

Laboratório 01

Importação e Manipulação de Dados em R

Benilton Carvalho, Guilherme Ludwig, Tatiana Benaglia

Introdução

Um conjunto de dados no formato tidy beneficia o analista de dados por permitir a manipulação dos mesmos de uma maneira unificada. De modo similar, métodos estatísticos são habitualmente implementados para receber dados neste formato. Desta maneira, a importação e tratamento de dados visando o referido formato reduzirá a criação de bancos de dados temporários, evitando problemas difíceis de diagnosticar.

Os conjuntos de dados apresentados correspondem ao número de casos de tuberculose observados em alguns países, juntamente com seus tamanhos populacionais.

Objetivos

Ao fim deste laboratório, você deverá ser capaz de:

- Caracterizar um conjunto de dados no formato tidy;
- Manipular bases de dados, para responder perguntas específicas, utilizando o arcabouço implementado via tidyverse, com uso de verbos do pacote dplyr e apresentação gráfica de resultados utilizando o pacote ggplot2;
- Notar que responder tais perguntas com bases de dados que não estejam no formato tidy requer trabalho adicional;

Manipulação de Dados no Formato Tidy

1. Carregue o pacote tidyverse

```
library(tidyverse)
```

```
## Warning: pacote 'tidyverse' foi compilado no R versão 4.6.1
```

```
## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr      1.2.1      v readr      2.2.0
## v forcats    1.0.1      v stringr    1.6.0
## v ggplot2    4.0.3      v tibble     3.3.1
## v lubridate  1.9.5      v tidyr      1.3.2
## v purrr      1.2.2
## -- Conflicts ----- tidyverse_conflicts() --
```

```
## x dplyr::filter() masks stats::filter()
## x dplyr::lag() masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

2. Apresente os bancos de dados table1, table2, table3, table4a e table4b, distribuídos juntamente com o pacote tidyverse. Para cada banco de dados, descreva textualmente se ele está no formato tidy e justifique cada uma de suas respostas.

table1

```
## # A tibble: 6 x 4
##   country    year cases population
##   <chr>      <dbl> <dbl>      <dbl>
## 1 Afghanistan 1999     745  19987071
## 2 Afghanistan 2000    2666  20595360
## 3 Brazil      1999   37737  172006362
## 4 Brazil      2000   80488  174504898
## 5 China       1999  212258  1272915272
## 6 China       2000  213766  1280428583
```

Resposta: Sim, o banco table1 está em formato tidy, pois cada coluna representa uma variável e cada linha representa uma observação

table2

```
## # A tibble: 12 x 4
##   country    year type      count
##   <chr>      <dbl> <chr>      <dbl>
## 1 Afghanistan 1999 cases        745
## 2 Afghanistan 1999 population 19987071
## 3 Afghanistan 2000 cases        2666
## 4 Afghanistan 2000 population 20595360
## 5 Brazil      1999 cases        37737
## 6 Brazil      1999 population 172006362
## 7 Brazil      2000 cases        80488
## 8 Brazil      2000 population 174504898
## 9 China       1999 cases        212258
## 10 China      1999 population 1272915272
## 11 China      2000 cases        213766
## 12 China      2000 population 1280428583
```

Resposta: Não, o banco table2 não está em formato tidy, pois a coluna type representa duas categorias diferentes e deveriam ser organizadas em colunas diferentes.

table3

```
## # A tibble: 6 x 3
##   country    year rate
##   <chr>      <dbl> <chr>
## 1 Afghanistan 1999 745/19987071
## 2 Afghanistan 2000 2666/20595360
## 3 Brazil      1999 37737/172006362
```

```
## 4 Brazil      2000 80488/174504898
## 5 China       1999 212258/1272915272
## 6 China       2000 213766/1280428583
```

Resposta: Não, o banco table3 não está em formato tidy, pois a coluna rate possui duas informações em uma única variável.

table4a

```
## # A tibble: 3 x 3
##   country      '1999' '2000'
##   <chr>        <dbl> <dbl>
## 1 Afghanistan    745   2666
## 2 Brazil        37737  80488
## 3 China         212258 213766
```

Resposta: Não, aqui temos duas colunas com nome referenciando os anos de 1999 e 2000, no formato longo (ou tidy) seria apropriado que essas informações fossem organizadas na variável “ano”.

table4b

```
## # A tibble: 3 x 3
##   country      '1999'      '2000'
##   <chr>        <dbl>      <dbl>
## 1 Afghanistan 19987071  20595360
## 2 Brazil      172006362  174504898
## 3 China       1272915272 1280428583
```

Resposta: Não, aqui temos duas colunas com nome referenciando os anos de 1999 e 2000, no formato longo (ou tidy) seria apropriado que essas informações fossem organizadas na variável “ano”.

3. Utilizando comandos do pacote dplyr, determine a taxa de ocorrência de tuberculose para cada 10.000 pessoas. Armazene o resultado em um objeto chamado taxas.

```
library(dplyr)

dados <- table1
taxas <- dados %>%
  mutate(taxa = cases/population * 10000)

taxas
```

```
## # A tibble: 6 x 5
##   country      year cases population  taxa
##   <chr>        <dbl> <dbl>      <dbl> <dbl>
## 1 Afghanistan 1999    745   19987071 0.373
## 2 Afghanistan 2000   2666   20595360 1.29
## 3 Brazil      1999  37737   172006362 2.19
## 4 Brazil      2000  80488   174504898 4.61
## 5 China       1999 212258  1272915272 1.67
## 6 China       2000 213766  1280428583 1.67
```

4. Apresente, utilizando comandos do pacote dplyr, o número de casos de tuberculose por ano.

```
casos_ano <- dados %>%
  group_by(year) %>%
  summarise(casos = sum(cases))
casos_ano
```

```
## # A tibble: 2 x 2
##   year casos
##   <dbl> <dbl>
## 1  1999 250740
## 2  2000 296920
```

5. Apresente, utilizando comandos do pacote dplyr, o número de casos de tuberculose identificados em cada país.

```
casos_pais <- dados %>%
  group_by(country) %>%
  summarise(total = sum(cases))
casos_pais
```

```
## # A tibble: 3 x 2
##   country      total
##   <chr>         <dbl>
## 1 Afghanistan    3411
## 2 Brazil         118225
## 3 China          426024
```

6. Utilizando comandos do pacote dplyr, apresente uma tabela que descreva a mudança no número de casos, em cada país, ao longo dos anos de 1999 e 2000.


```
mudanca_numero_casos <- dados %>%
  arrange(country, year) %>%
  group_by(country) %>%
  mutate(mudanca = cases - lag(cases)) %>%
  filter(year == 2000) %>%
  select(country, mudanca)
mudanca_numero_casos
```

```
## # A tibble: 3 x 2
## # Groups:   country [3]
##   country      mudanca
##   <chr>         <dbl>
## 1 Afghanistan    1921
## 2 Brazil         42751
## 3 China          1508
```

7. Apresente um gráfico de linhas, preparado via ggplot2, apresentando a mudança na taxa de casos (por 10.000 habitantes) estratificado por país.

```
library(ggplot2)
grafico <- ggplot(taxas, aes(x = year, y = taxa, group = country, colour = country)) +
  geom_line() +
  geom_point() +
  labs(x = "Ano", y = "Taxa de casos por 10 000 habitantes", color = "País") +
  theme_minimal()

grafico
```



8. Calcule a taxa para as tabelas table2 e table4a+table4b. Para isso, você precisará executar 4 passos:

Extrair o número de casos de tuberculose por país, por ano; Extrair o tamanho da população correspondente, por ano; Dividir o número de casos pelo tamanho da população e multiplicar o resultado por 10.000; Armazenar o resultado numa variável apropriada;

```
#para table2

casos_table2 <- table2 %>%
  filter(type == "cases")%>%
  select(country, year, count)

populacao_table2 <- table2 %>%
  filter(type == "population")%>%
  select(country, year, count)

taxa_tabela2 <- casos_table2 %>%
```

```
mutate(taxa = count/populacao_table2$count * 10000)
taxa_tabela2
```

```
## # A tibble: 6 x 4
##   country    year count  taxa
##   <chr>      <dbl> <dbl> <dbl>
## 1 Afghanistan 1999    745 0.373
## 2 Afghanistan 2000   2666 1.29
## 3 Brazil      1999  37737 2.19
## 4 Brazil      2000 80488 4.61
## 5 China       1999 212258 1.67
## 6 China       2000 213766 1.67
```

#para table4a + table4b

```
casos_table4a <- table4a %>%
  pivot_longer(
    cols = c(`1999`, `2000`),
    names_to = "year",
    values_to = "cases"
  )
casos_table4a
```

```
## # A tibble: 6 x 3
##   country    year cases
##   <chr>      <chr> <dbl>
## 1 Afghanistan 1999    745
## 2 Afghanistan 2000   2666
## 3 Brazil      1999  37737
## 4 Brazil      2000  80488
## 5 China       1999 212258
## 6 China       2000 213766
```

```
populacao_table4b <- table4b %>%
  pivot_longer(
    cols = c(`1999`, `2000`),
    names_to = "year",
    values_to = "population"
  )
populacao_table4b
```


```
## # A tibble: 6 x 3
##   country    year population
##   <chr>      <chr>      <dbl>
## 1 Afghanistan 1999  19987071
## 2 Afghanistan 2000  20595360
## 3 Brazil      1999  172006362
## 4 Brazil      2000  174504898
## 5 China       1999 1272915272
## 6 China       2000 1280428583
```

```
taxa_tabela4 <- casos_table4a %>%
  mutate(taxa = cases/ populacao_table4b$population * 10000)
taxa_tabela4
```

```
## # A tibble: 6 x 4
##   country    year  cases  taxa
##   <chr>      <chr> <dbl> <dbl>
## 1 Afghanistan 1999     745 0.373
## 2 Afghanistan 2000    2666 1.29
## 3 Brazil      1999   37737 2.19
## 4 Brazil      2000   80488 4.61
## 5 China       1999  212258 1.67
## 6 China       2000  213766 1.67
```

9. Refaça o gráfico da questão 7 para os dados apresentados em table2.

```
grafico2 <- ggplot(taxa_tabela2, aes(x = year, y = taxa, group = country, colour = country)) +
  geom_line() +
  geom_point() +
  labs(x = "Ano", y = "Taxa de casos por 10 000 habitantes", color = "País") +
  theme_minimal()
grafico2
```



10. Utilizando o comando `pivot_longer`, transforme table4a em um objeto no formato tidy. Armazene o resultado num objeto chamado tidy4a.

```
tidy4a <- table4a %>%
  pivot_longer(
    cols = c('1999', '2000'),
    names_to = "ano",
    values_to = "casos"
  )
```

11. Refaça o item 10 para o objeto table4b. Armazene o resultado num objeto chamado tidy4b.

```
tidy4b <- table4b %>%
  pivot_longer(
    cols = c('1999', '2000'),
    names_to = "ano",
    values_to = "população"
  )
```

12. Combine os objetos tidy4a e tidy4b em um único objeto, utilizando o comando left_join. Apresente uma explicação textual sobre o que faz o referido comando.

```
tabela4 <- left_join(
  tidy4a,
  tidy4b,
  by = c("country", "ano")
)
```

tabela4

```
## # A tibble: 6 x 4
##   country      ano   casos população
##   <chr>      <chr> <dbl>      <dbl>
## 1 Afghanistan 1999     745   19987071
## 2 Afghanistan 2000    2666  20595360
## 3 Brazil      1999   37737  172006362
## 4 Brazil      2000   80488  174504898
## 5 China       1999  212258 1272915272
## 6 China       2000  213766 1280428583
```

Resposta: o comando left_join compara as linhas da tabela à esquerda com as da direita, mantém as linhas da esquerda e adiciona as linhas diferentes da tabela à direita, formando assim uma única tabela sem conflitos de informações. Caso não haja correspondência, ele não cria uma observação e sim adiciona uma célula NA. No exemplo acima as colunas comparadas foram “country” e “ano”, ou seja, quando essas duas informações coincidiram ele pode completar a linha de observações unindo as informações contidas nas duas tabelas.

13. Use o comando pivot_wider para transformar o objeto table2 em um objeto com formato tidy.

```
tabela2 <- table2 %>%
  pivot_wider(
    names_from = type,
    values_from = count
  )
```

tabela2


```
## # A tibble: 6 x 4
##   country    year cases population
##   <chr>      <dbl> <dbl>      <dbl>
## 1 Afghanistan 1999    745  19987071
## 2 Afghanistan 2000   2666  20595360
## 3 Brazil      1999  37737  172006362
## 4 Brazil      2000  80488  174504898
## 5 China       1999 212258 1272915272
## 6 China       2000 213766 1280428583
```

14. Observe que a coluna `rate` do objeto `table3` é um texto mostrando a fração que formaria a taxa de casos de tuberculose. Transforme o objeto `table3` em um objeto com formato tidy separando a coluna 3 em duas outras colunas: `cases` e `population`, utilizando o comando `separate`. Utilize o argumento `convert` para transformar o resultado em um objeto numérico.

```
tabela3 <- table3 %>%
  separate(
    rate,
    into = c("cases", "population"),
    sep = "/",
    convert = TRUE
  )
tabela3
```

```
## # A tibble: 6 x 4
##   country    year cases population
##   <chr>      <dbl> <int>      <int>
## 1 Afghanistan 1999    745  19987071
## 2 Afghanistan 2000   2666  20595360
## 3 Brazil      1999  37737  172006362
## 4 Brazil      2000  80488  174504898
## 5 China       1999 212258 1272915272
## 6 China       2000 213766 1280428583
```