

lab03_leila_kawanishi_277185

Leila Kawanishi

Laboratório 3: Dados relacionais e operações do tipo join

Benilton Carvalho, Guilherme Ludwig

Introdução

Conjuntos de dados estruturados costumam ser divididos em múltiplas tabelas. A razão para isso é a minimização de duplicação de informação. Por este motivo, uma tarefa habitualmente realizada em manipulação de bases de dados é a combinação de dados de diferentes origens.

Objetivos

Ao fim deste laboratório, você deve ser capaz de combinar duas tabelas de dados, de forma que, na tabela resultante, sejam mantidos registros que existam:

- em ambas as tabelas;
- apenas na primeira tabela;
- apenas na segunda tabela;
- em alguma das duas tabelas.

Adicionalmente, você deve ser capaz de identificar registros que existam:

- apenas na primeira tabela;
- apenas na segunda tabela;

Carregue os pacotes relevantes para este Laboratório

Atrasos de vôos

Considere novamente o problema de atrasos de vôos, disponível em <https://www.kaggle.com/usdot/flight-delays>. Nesta atividade, além dos dados de `flights.csv`, nós iremos utilizar informações disponíveis nos arquivos `airlines.csv` e `airports.csv`.

1. Importe, utilizando o pacote `readr`, cada um dos três arquivos disponíveis. Os objetos resultantes devem ser chamados `flights`, `airlines` e `airports`.
 - Para o arquivo de aeroportos, importe apenas as colunas `IATA_CODE`, `CITY`, `STATE`, `LATITUDE`, `LONGITUDE`;
 - Para o arquivo de vôos: Importe apenas as colunas `DESTINATION_AIRPORT` e `ARRIVAL_DELAY`; Leia apenas 1 milhão de linhas por vez; Remova vôos em que o aeroporto de destino comece com a letra 1; Remova registros em que existam pelo menos uma coluna faltante; Determine, para cada parte do arquivo, as estatísticas suficientes para a determinação do atraso médio por aeroporto de destino; Ao finalizar a leitura do arquivo, combine as estatísticas suficientes de modo a produzir a média de atraso por aeroporto.
2. Selecione a operação apropriada `join` para incluir, na tabela `flights`, as colunas `CITY` e `STATE` do objeto `airports`. Para executar esta tarefa:
 - Identifique a coluna que é a chave na tabela `flights`;
 - Identifique a coluna que é a chave na tabela `airports`;
 - Quais são os aeroportos que estão listados em `flights`, mas estão ausentes em `airports`?
 - Apresente o comando que combine ambas as tabelas, indicando explicitamente as chaves;
 - Armazene a tabela resultante no objeto `flights`.
3. Quantos aeroportos cada estado possui? Apresente uma tabela ordenada de forma decrescente (no número de aeroportos).
4. Apresente um mapa representando todos os atrasos observados por aeroporto.
 - Carregue o pacote `leaflet`;
 - Combine os comandos `leaflet`, `addTiles` e `addMarkers` para a criação de um mapa básico;
 - Armazene o grafico em b) numa variável chamada `this`;
 - Adicione as duas linhas abaixo após a criação da variável `this` (apenas se você estiver usando Jupyter):